

Acabou, não tem mais jeito:
Uma análise dos impactos da emissão de CO₂ na mortalidade populacional e aquecimento global através de séries temporais

**Álvaro Lopes, João Constantino, Matheus Cerqueira,
Natan Sanches, Leonardo Pereira**

Instituto de Ciências Matemáticas e de Computação
Universidade de São Paulo (USP)
São Carlos, SP – Brasil

{alvarojoselopes, jlconstantino, matheuscerqueira,
natan.sanches, leonardop}@usp.br

Abstract. *During the last decades, economic growth was followed by an increasing tendency of CO₂ emissions over the globe, bringing with it many environmental impacts that can be noticed by several climate anomalies. In this paper, we propose a brief time series analysis aiming to better understand the impacts of the CO₂ emission in the average global temperature and in deaths by respiratory related diseases. Additionally, we also present a tendency analysis of these data in the following years, using robust time series forecasting methods.*

Resumo. *Nas últimas décadas, o crescimento econômico global foi acompanhado pelo aumento das emissões de CO₂ em todo o globo, trazendo diversos impactos ambientais que puderam ser notados pela população através de anomalias climáticas. Neste trabalho, propõe-se uma análise para melhor entendimento do impacto do aumento das emissões de CO₂ na temperatura média global e no número de mortes por doenças respiratórias, fundamentalmente baseada em séries temporais. É apresentado, ainda, uma previsão da tendência desses dados nos próximos anos, utilizando métodos estatísticos robustos de previsão dessas séries.*

1. Introdução

Nas últimas quatro décadas, o crescimento econômico global triplicou, trazendo melhores padrões de vida, mas também contribuindo para o aumento das emissões de CO₂ e o esgotamento dos recursos naturais. Essas emissões, influenciadas por fatores sociais, econômicos e industriais, resultam de várias atividades, como a queima de combustíveis fósseis e o desmatamento. Nas últimas duas décadas, vários estudos exploraram a intrincada conexão entre crescimento econômico, uso de energia e emissões de CO₂. Essas investigações, empregando diversas metodologias, mostraram vínculos entre o crescimento econômico, o consumo de biocombustíveis e as emissões de CO₂, enfatizando a complexidade da questão. Enquanto alguns estudos argumentam que o crescimento econômico causa diretamente as emissões de CO₂, outros sugerem uma relação causal mútua. Uma terceira perspectiva, a hipótese da neutralidade, não apresenta nenhuma relação causal, defendendo políticas de conservação de energia que não prejudiquem o crescimento econômico [Mardani et al. 2019].

As temperaturas globais aumentaram $0,74^{\circ}\text{C}$ no período entre 1906 a 2005 e espera-se que aumentem significativamente no futuro, o que pode levar a riscos meteorológicos e eventos extremos mais frequentes e intensos. As emissões de CO_2 elevadas foram identificadas como um dos principais impulsionadores do aquecimento global, com estudos enfatizando sua associação com os gases de efeito estufa. As atividades humanas, especialmente desde a revolução industrial, causaram um rápido aumento nas emissões globais de gases de efeito estufa, resultando em concentrações de CO_2 e CH_4 que atingiram níveis nunca vistos nos últimos 65 milhões de anos. Embora muitos estudos atribuam o aquecimento ao aumento das emissões de CO_2 , quantificar o impacto exato no aumento da temperatura é um desafio devido às incertezas nos modelos climáticos, às estimativas de emissão de gases de efeito estufa, à sensibilidade da temperatura ao conteúdo de CO_2 e aos dados observacionais limitados. Diferentes estudos sugerem estimativas variadas de aumento de temperatura, que vão de $0,48^{\circ}\text{C}$ a $5,0^{\circ}\text{C}$ para concentrações dobradas de CO_2 . A sensibilidade da temperatura à concentração de CO_2 ainda não está clara, o que gera a necessidade de um entendimento quantitativo [Chen et al. 2014].

Os cenários apresentados de poluição do ar e de mudanças climáticas estão intrinsecamente conectados, afetando a saúde das pessoas com base no tipo e na fonte de poluentes e nas condições climáticas. As mudanças nas condições climáticas pioram significativamente a saúde respiratória em adultos com doenças pulmonares crônicas, como asma e DPOC, levando ao aumento da morbidade e da mortalidade. Algumas mortes são atribuídas a eventos extremos, fazendo com que os indivíduos com doenças pulmonares se proliferem mais cedo do que o esperado; ciclones têm sido associados à asma, e o clima frio aumenta as infecções respiratórias em indivíduos com doenças pulmonares devido à maior exposição ao frio. Diretamente, pesquisas apontam o material particulado (um composto de diversos materiais, incluindo CO_2) e o ozônio como os principais contribuintes para os problemas respiratórios causados pela poluição do ar. Indiretamente, a poluição do ar interage com alérgenos, piorando as alergias respiratórias, e as evidências sugerem que as mudanças climáticas e a poluição do ar contribuem para doenças respiratórias mais graves [D'Amato et al. 2014].

Do ponto de vista técnico e analítico, a modelagem de séries temporais é uma técnica importante e bem estabelecida em pesquisas acadêmicas, tanto na Computação, quanto em áreas que se usam de suas técnicas. Ela desempenha um papel crucial em várias áreas, como modelagem climática, ciências biológicas, medicina, tomada de decisões no varejo e finanças. Métodos tradicionais, baseados na experiência prática, incluem modelos autorregressivos (AR), de suavização exponencial e de séries temporais estruturais [Lim and Zohren 2021]. Neste trabalho, abordaremos os impactos das emissões de CO_2 , com foco na mortalidade por doenças respiratórias e no aumento da temperatura global¹. Utilizaremos técnicas de aprendizado de máquina em séries temporais para identificar semelhanças entre séries e prever tendências futuras, proporcionando uma compreensão mais aprofundada dos impactos, correlações e tendências dos fenômenos. As seções seguintes apresentam: 2, trabalhos relacionados que utilizam técnicas semelhantes na mesma temática; 3, nossa abordagem e técnicas empregadas; 4, nossos resultados; e 5, conclusões e possíveis trabalhos futuros.

¹Disponível em: <https://github.com/CerqueiraMatheus/time-series>

2. Trabalhos Relacionados

No estudo conduzido em [Hosseini et al. 2019], a problemática das emissões de CO_2 no Irã é abordada, destacando que o país se tornou um dos maiores emissores desse gás nas últimas décadas, com índices de emissões próximos a países como Japão e Alemanha nesse aspecto; apesar disso, o Produto Interno Bruto (PIB) do Irã é inferior à soma dos PIBs de Berlim e Tóquio. O estudo aponta que uma grande parte da receita do Irã advém da exportação de petróleo bruto, indicando que o nível de emissões de CO_2 não é necessariamente impulsionado economicamente, mas é resultado da alta intensidade energética no país. O governo, entretanto, não possui um programa claro para lidar com essa questão. O Sexto Plano de Desenvolvimento Quinquenal do Irã estabelece metas ambiciosas relacionadas principalmente à intensidade energética, crescimento do PIB e energias renováveis, mas não aborda explicitamente a questão das emissões de CO_2 . Assim, objetivo do estudo é prever as emissões de CO_2 do Irã em 2030 sob duas suposições: o cenário de continuidade (BAU) e o Sexto Plano de Desenvolvimento (SDP), utilizando análises de regressão linear múltipla (MLR) e regressão polinomial múltipla (MPR). Os resultados indicam que, de acordo com as previsões realizadas, é provável que o Irã não cumpra suas metas no âmbito do Acordo de Paris, enquanto a implementação total do SDP possa ser realizada até final de 2018.

[Mudelsee 2019] examina a tendência crescente da temperatura global da superfície ao longo do tempo desde o século XIX, destacando a influência significativa das atividades humanas no clima desde a industrialização. O artigo destaca o papel da ciência estatística em quantificar numericamente o aquecimento, indo além do debate público e político que circunda o fenômeno. A estatística desenvolve métodos para quantificar a tendência de aquecimento, identificar pontos de mudança e fornecer medidas de incerteza, como barras de erro, essenciais para a interpretação de qualquer curva estimada. Métodos estatísticos avançados, intensivos em computação, são empregados, considerando as peculiaridades dos dados climáticos, como a distribuição não gaussiana e a autocorrelação. A confiabilidade desses métodos é confirmada por simulações de Monte Carlo usando dados artificiais. A aplicação desses métodos à série temporal GISTEMP da temperatura global da superfície revela um aquecimento acelerado desde 1974. O estudo indica que um pico relativo de aquecimento ao redor da Segunda Guerra Mundial pode ser mais uma artefato de qualidade inferior dos dados daquela época do que uma característica real. Além disso, a análise estatística não identifica uma pausa significativa no aquecimento global após 1998, sugerindo que qualquer aparente hiato, até 2013, é resultado da seleção do intervalo de ajuste. Ao estender o intervalo até 2017, não há evidência significativa de hiato.

Em [Mason et al. 2019], foi investigada a eficácia do Índice de Saúde da Qualidade do Ar (AQHI) de Hong Kong na mitigação do impacto de curto prazo da poluição do ar na morbidade respiratória. Utilizando um desenho quase experimental e uma análise de séries temporais interrompidas com regressão segmentada de Poisson de 2010 a 2016, o estudo avaliou as mudanças nas admissões hospitalares de emergência por doenças respiratórias após a implementação da política do AQHI em 30 de dezembro de 2013. A análise, ajustada para vários poluentes do ar, temperatura e umidade, revelou uma redução imediata de 14% nas admissões por infecções do trato respiratório (ITR) após a implementação do AQHI. Notavelmente, essa redução foi observada predominantemente em crianças, com análises específicas por idade indicando diminuições imediatas

nas admissões hospitalares por ITR e pneumonia. Esses resultados destacam o impacto positivo do AQHI na redução das hospitalizações relacionadas a doenças respiratórias, especialmente entre as crianças. As descobertas do estudo enfatizam os potenciais benefícios à saúde dos programas de alerta de qualidade do ar, enfatizando a necessidade de esforços direcionados para garantir que populações em risco possam aderir efetivamente às mudanças comportamentais recomendadas pelas advertências do AQHI.

[Ren et al. 2017] enfatiza que poucas pesquisas compararam diferentes métodos ao explorar os efeitos de curto prazo de poluentes do ar na mortalidade por doenças respiratórias em Wuhan, China. Assim, estudo avaliou a associação entre poluentes do ar e mortalidade por doenças respiratórias usando tanto modelos de séries temporais quanto modelos de estudo de caso-cruzado estratificado por tempo. O modelo aditivo generalizado (GAM) e o modelo de regressão logística condicional foram empregados para avaliar os efeitos de curto prazo dos poluentes do ar na mortalidade por doenças respiratórias. Análises estratificadas foram realizadas por idade, sexo e doenças. Evidências consistentes de uma associação entre NO_2 e a mortalidade diária por doenças respiratórias em homens ou pessoas com mais de 65 anos foram encontradas no estudo de caso-cruzado. Houve uma associação positiva entre poluentes do ar e mortalidade por doenças respiratórias em Wuhan, China. As análises de séries temporais e estudo de caso-cruzado consistentemente revelaram a associação entre três poluentes do ar e a mortalidade por doenças respiratórias. As estimativas de associação entre poluição do ar e mortalidade por doenças respiratórias a partir da análise de caso-cruzado exibiram maior variação do que aquelas da análise de séries temporais.

3. Materiais e Métodos

3.1. Conjuntos de Dados

Para a análise proposta, foram utilizados quatro conjuntos de dados que complementam-se entre si: **CO₂ Emissions from Fossil Fuels since 1751** [Carbon Dioxide Information Analysis Center 2021] apresenta dados sobre a emissão total de dióxido de carbono (CO_2), em milhões de toneladas de carbono, de diferentes países do globo. **Health Status: Mortality** [Organisation for Economic Co-operation and Development 2017b] apresenta dados que permitem analisar o número de mortes por doenças respiratórias, nos últimos anos, em diferentes países e permite entender se, nesse aspecto, o aumento da emissão de CO_2 teve influência significativa. Além disso, **Health Status: Life expectancy** [Organisation for Economic Co-operation and Development 2017a] fornece informações importantes sobre o aumento na expectativa de vida ao longo do tempo de maior parte dos países do globo, com intuito de entender o avanço da medicina neste período e considerá-lo na análise. Por fim, foi proposta uma análise de correlação entre os dados adquiridos e o aumento da temperatura média global nos últimos anos, a partir de **Annual Mean Temperature Change over Land and over Ocean** [National Aeronautics Space Administration 2020].

3.2. Algoritmos

3.2.1. DTW

O DTW, ou *Dynamic Time Warping*, é um conhecido algoritmo utilizado para medir a similaridade entre duas séries temporais que podem, por exemplo, não estar perfeitamente alinhadas. De maneira mais precisa, o algoritmo é responsável por encontrar o alinhamento ótimo entre duas séries temporais e era, inicialmente, utilizado para comparar diferentes padrões de fala no escopo de reconhecimento automático de fala [Müller 2007].

O algoritmo busca comparar duas séries temporais $X = (x_1, x_2, \dots, x_n)$ e $Y = (y_1, y_2, \dots, y_m)$, de tamanhos n e m , respectivamente. Para isso, exige que se tenha uma função de custo $c : X \times Y \rightarrow \mathbb{R}_{>0}$ responsável por quantificar a similaridade entre um ponto $x \in X$ e um ponto $y \in Y$. Espera-se, portanto, que $c(x, y)$ seja pequeno quanto mais similares forem os pontos x e y ; no caso de serem pontos dissimilares, $c(x, y)$ é grande. O resultado de se computar os custos locais para cada um dos pares de X e Y é uma *matriz de custo*, $C \in \mathbb{R}^{n \times m}$, de forma que $C(i, j) := c(x_i, y_j)$. O objetivo do DTW é encontrar um alinhamento entre X e Y de forma que o custo geral desse alinhamento seja o menor possível a partir de C [Müller 2007].

Define-se por *alinhamento* uma sequência $p = (p_1, p_2, \dots, p_k)$ de tamanho k , onde $p_i = (n_i, m_i) \in [1 : n] \times [1 : m]$, para $i \in [1 : k]$ satisfazendo algumas condições. O custo total de um alinhamento p de X e Y , $c_p(X, Y)$, é descrito pela relação

$$c_p(X, Y) = \sum_{i=1}^k c(x_{n_i}, y_{m_i}) \quad (1)$$

e, a partir de (1), pode-se definir o *alinhamento ótimo*, p^* , como sendo o alinhamento com menor custo de todos os possíveis. Isto é, sendo

$$c_{p^*}(X, Y) = \min \{c_p(X, Y) \mid p \text{ é um alinhamento possível}\} \quad (2)$$

o que o DTW busca encontrar [Müller 2007].

Neste trabalho, o *Dynamic Time Warping* foi utilizado como uma das principais metodologias para estimar a similaridade entre as séries temporais de nossos conjuntos de dados, de maneira a encontrar possíveis correlações entre elas. Além do DTW, outros métodos estatísticos clássicos foram utilizados, como a correlação de Pearson e Spearman.

3.2.2. ARIMA

No estudo de séries temporais, um dos métodos mais utilizados para se converter uma série temporal não-estacionária em uma série temporal estacionária (isto é, cujas propriedades estatísticas não dependem do tempo) é o de *diferenciação*, que consiste em computar diferenças entre observações consecutivas nessa série. A diferenciação, portanto, gera uma nova série temporal $Y' = (y'_1, y'_2, \dots, y'_n)$ a partir de $Y = (y_1, y_2, \dots, y_n)$ que respeita a relação

$$y'_t = y_t - y_{t-1}, \quad t \in [1 : n] \quad (3)$$

no caso de uma diferenciação de primeira ordem [Hyndman and Athanasopoulos 2018]. Analogamente, uma diferenciação de m -ésima ordem pode ser descrita de forma similar e recursiva, originando uma série temporal $Y^{(m)} = (y_1^{(m)}, y_2^{(m)}, \dots, y_n^{(m)})$ a partir da relação

$$y_t^{(m)} = y_t^{(m-1)} - y_{t-1}^{(m-1)}, \quad t \in [1 : n], \quad m \geq 1. \quad (4)$$

Além disso, a utilização de *modelos autoregressivos* e *modelos de média movel* são muito comuns tratando-se de previsões em séries temporais. Um modelo autoregressivo de ordem p , **AR**(p), baseia-se em realizar a previsão de uma variável a partir de uma combinação linear de p estados passados dessa variável, e é definido da forma

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t \quad (5)$$

onde $\phi_i, i \in [1 : p]$, são os coeficientes dessa regressão e ε_t é o termo de erro dessa previsão. Um modelo de média móvel de ordem q , **MA**(q), por outro lado, utiliza de erros de previsão passados para compor a regressão ao invés de estados passados

$$y_t = c + \theta_1 \varepsilon_{t-1} + \theta_2 \varepsilon_{t-2} + \dots + \theta_q \varepsilon_{t-q}. \quad (6)$$

onde ε_t é o ruído branco. Como as variáveis ε_t são variáveis aleatórias e não há observação destas, o modelo de média móvel não é uma regressão no sentido comum [Hyndman and Athanasopoulos 2018].

O ARIMA, ou *Autoregressive Integrated Moving Average*, origina-se a partir da junção do modelo autoregressivo fundamental com o modelo de média movel e é um modelo de previsão de séries temporais que combina diferenciação com autoregressão. Matematicamente, o modelo completo pode ser descrito pela relação

$$y'_t = c + \phi_1 y'_{t-1} + \dots + \phi_p y'_{t-p} + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (7)$$

onde y'_t é a série diferenciada. O modelo, nesse caso, realiza a predição em função de valores com latência de y_t de ordem p e erros com latência de ε_t de ordem q [Hyndman and Athanasopoulos 2018].

Denomina-se, de forma geral, um modelo ARIMA da forma **ARIMA**(p, d, q), onde os parâmetros p, d e q são análogos aos presentes em (7). Mais precisamente, p refere-se à ordem da parte autoregressiva, d refere-se ao grau da primeira diferenciação envolvida e q refere-se a ordem da média movel.

Neste trabalho, modelos **ARIMA**(p, d, q) foram otimizados individualmente para cada caso, de forma a fazer previsões para anos futuros das séries temporais que descrevem a emissão de carbono e a mortalidade por doenças respiratórias, para cada país. Além disso, também foi feito um estudo de como se comportará a anomalia na temperatura média global ao longo dos próximos anos.

3.3. Abordagem

A abordagem adotada nesse trabalho pode ser dividida em 3 etapas: (I) pré-processamento das séries temporais, (II) aplicação dos algoritmos para cálculo de similaridade/correlação entre séries temporais e *forecasting*, seguida pela (III) aplicação de testes de hipótese quando aplicável.

Para a etapa (i), foi necessário selecionar os países e o período a ser analisado, uma vez que os dados são provenientes de diferentes fontes, contendo diferentes países ou diferenças do período amostrado. Para realizar essa filtragem, o critério utilizado foi selecionar os países presentes em todos os *datasets* (**46 países**) e o período de tempo comum a todos os dados (anos de **1960 a 2014**).

Para a etapa (II), os algoritmos utilizados para cálculo da similaridade/correlação entre séries temporais utilizados foram: **Correlação de Pearson**, **Correlação de Spearman** e **DTW**. Essas métricas foram selecionadas com o propósito de investigar possíveis relações entre as séries temporais de emissão de carbono e a incidência de mortes por doenças respiratórias, assim como entre a emissão de carbono e as variações na temperatura global. Para a primeira análise, também foi adotada a ponderação da incidência de mortes por doenças respiratórias pela expectativa de vida, a fim de mitigar o impacto do progresso da medicina sobre as taxas de mortalidade.

Ainda na etapa (II), o algoritmo utilizado para *forecasting* foi o **ARIMA**. As previsões foram feitas para todos os conjunto de dados e, para aqueles que possuem séries temporais para vários países, um modelo foi treinado para cada país. Para otimizar os parâmetros de cada um desse modelos, foi utilizada a biblioteca **Optuna** a fim de encontrar os melhores parâmetros p, q, d que minimizam o erro quadrático médio nos dados de treino (80%).

Por fim, para a etapa (III) foram utilizados os teste de hipótese **Mann-Whitney U Test** e **Kruskal-Wallis H Test** para comparação das métricas de similaridade. E para verificação de dependência linear foram utilizados os teste de **Shapiro** para verificação de normalidade e **Spearman** para verificação de linearidade.

4. Resultados e Discussão

4.1. Análises de similaridade

Inicialmente, comparamos a emissão de carbono global com o aumento da temperatura global. Conforme apresenta a Figura 4.1, a série de aumento das temperaturas e de emissões se acompanham ao longo dos anos, com uma baixa DTW ($= 3.64$), num alto nível de correlação de Spearman ($= .91$). Tal observação vai de encontro aos apontamentos realizados em [Mudelsee 2019], que explicita a correlação entre aumento de temperatura e emissões de carbono em múltiplos contextos.




Figura 1. Séries de emissão de carbono global e de aumento de temperatura

Em seguida, passamos à análise correlacionando as taxas de morte por doenças respiratórias e emissão de carbono. Por razões de disposição do texto, elas seguem na seção de Apêndices. Ambas as Figuras 3 e 4 apresentam as similaridades entre as duas séries. Na Figura 3, dos 46 países selecionados, 27 (58.7%) apresentam similaridade estatisticamente significativa. Isso demonstra que as emissões de carbono são significantes para o modal de mortalidade, mas não necessariamente determinantes.

Como hipótese, também foi realizada uma segunda versão do teste realizado na Figura 3, mas aplicando uma ponderação pela razão entre a expectativa de vida no ano e a maior expectativa de vida alcançada por aquele país. Assim, esperava-se que o fator de melhoria na qualidade de vida fosse atenuado nos resultados; no entanto, a proposta, mostrou-se insuficiente. Conforme apresenta a 4, novamente, dos 46 países selecionados, 27 (58.7%) apresentaram similaridade estatisticamente significativa.

4.2. Previsões

Para complementar a análise, foram feitas previsões de tendência para as séries temporais que descrevem a emissão de CO_2 por país (Figura 5), o número de mortes por doenças respiratórias por país (Figura 6) e, finalmente, a temperatura média global (Figura 2) até o ano de 2029, com utilização do modelo **ARIMA**. Para considerar o aumento na qualidade de vida ao longo do tempo, a previsão também foi aplicada para a série de mortalidade por doenças respiratórias ponderada pela expectativa de vida (Figura 7).




Figura 2. Similaridade entre a emissão de carbono e mortalidade por doenças respiratórias ponderada por expectativa de vida

Por essa análise, não foi possível notar uma tendência comum a todos os países quando tratando-se da mortalidade por doenças respiratórias, e da emissão de CO₂: os resultados envolveram tipos diferentes de tendências (crescimento, decrescimento ou constante) para os diferentes países, não havendo algum tipo de homogeneidade. Esse resultado faz sentido, ao considerar-se que o nível de industrialização do país está intrinsecamente ligado à emissão de CO₂.

Além disso, não foi possível notar grande diferença ao ponderar-se a mortalidade por doenças respiratórias pela expectativa de vida no nascimento. Por fim, para a temperatura global, nota-se uma contínua tendência de crescimento para os próximos anos, que corrobora com o fenômeno do aquecimento global no estudo feito por [Mudelsee 2019].

5. Conclusões e Trabalhos Futuros

Por meio dos experimentos, não foi possível observar uma correlação linear global entre o aumento das emissões de carbono e o aumento da mortalidade por doenças respiratórias. Entretanto, é importante destacar a existência de um grande percentual de países com uma correlação linear estatisticamente significativa de 58,70% – 27 dos 46 países analisados.

Por outro lado, notou-se uma dependência linear estatisticamente significativa entre o aumento da temperatura e o aumento da emissão de carbono, corroborando o consenso científico sobre o fenômeno do aquecimento global [Mudelsee 2019].

Na segunda etapa dos experimentos, envolvendo a previsão das séries temporais, pode-se notar que a previsão futura para a temperatura global segue uma tendência de crescimento linear, corroborando novamente com os estudos sobre o fenômeno de aquecimento global [Mudelsee 2019].

Para trabalhos futuros, é possível explorar a granularidade das emissões de carbono, incluindo uma análise mais detalhada que considere a inter-relação entre países vizinhos, como o impacto de países mais industrializados sobre seus vizinhos. Além disso, um próximo caminho seria investigar a aplicação de diferentes algoritmos de *forecasting* para aprimorar a precisão das projeções futuras realizadas.

Referências

- Carbon Dioxide Information Analysis Center (2021). Co₂ emissions from fossil fuels since 1751, by nation.
- Chen, Y., Li, B., Li, Z., and Shi, X. (2014). Quantitatively evaluating the effects of co₂ emission on temperature rise. *Quaternary International*, 336:171–175. Large Asian Rivers VII.
- D’Amato, G., Cecchi, L., D’Amato, M., and Annesi-Maesano, I. (2014). Climate change and respiratory diseases. *European Respiratory Review*, 23(132):161–169.
- Hosseini, S. M., Saifoddin, A., Shirmohammadi, R., and Aslani, A. (2019). Forecasting of co₂ emissions in iran based on time series and regression analysis. *Energy Reports*, 5:619–631.
- Hyndman, R. J. and Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*, chapter 8. OTexts: Melbourne, Australia.
- Lim, B. and Zohren, S. (2021). Time-series forecasting with deep learning: a survey. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 379(2194):20200209.
- Mardani, A., Streimikiene, D., Cavallaro, F., Loganathan, N., and Khoshnoudi, M. (2019). Carbon dioxide (co₂) emissions and economic growth: A systematic review of two decades of research from 1995 to 2017. *Science of The Total Environment*, 649:31–49.
- Mason, T. G., Schooling, C. M., Chan, K. P., and Tian, L. (2019). An evaluation of the air quality health index program on respiratory diseases in hong kong: An interrupted time series analysis. *Atmospheric Environment*, 211:151–158.
- Mudelsee, M. (2019). Trend analysis of climate time series: A review of methods. *Earth-Science Reviews*, 190:310–322.
- Müller, M. (2007). *Dynamic Time Warping*, pages 69–84. Springer Berlin Heidelberg, Berlin, Heidelberg.
- National Aeronautics Space Administration (2020). Annual mean temperature change over land and over ocean.
- Organisation for Economic Co-operation and Development (2017a). Health status: Life expectancy.
- Organisation for Economic Co-operation and Development (2017b). Health status: Mortality.
- Ren, M., Li, N., Wang, Z., Liu, Y., Chen, X., Chu, Y., Li, X., Zhu, Z., Tian, L., and Xiang, H. (2017). The short-term effects of air pollutants on respiratory disease mortality in wuhan, china: comparison of time-series and case-crossover analyses. *Scientific Reports*, 7(1):40482.

Apêndices

A. Similaridade entre a emissão de carbono e mortalidade, por país

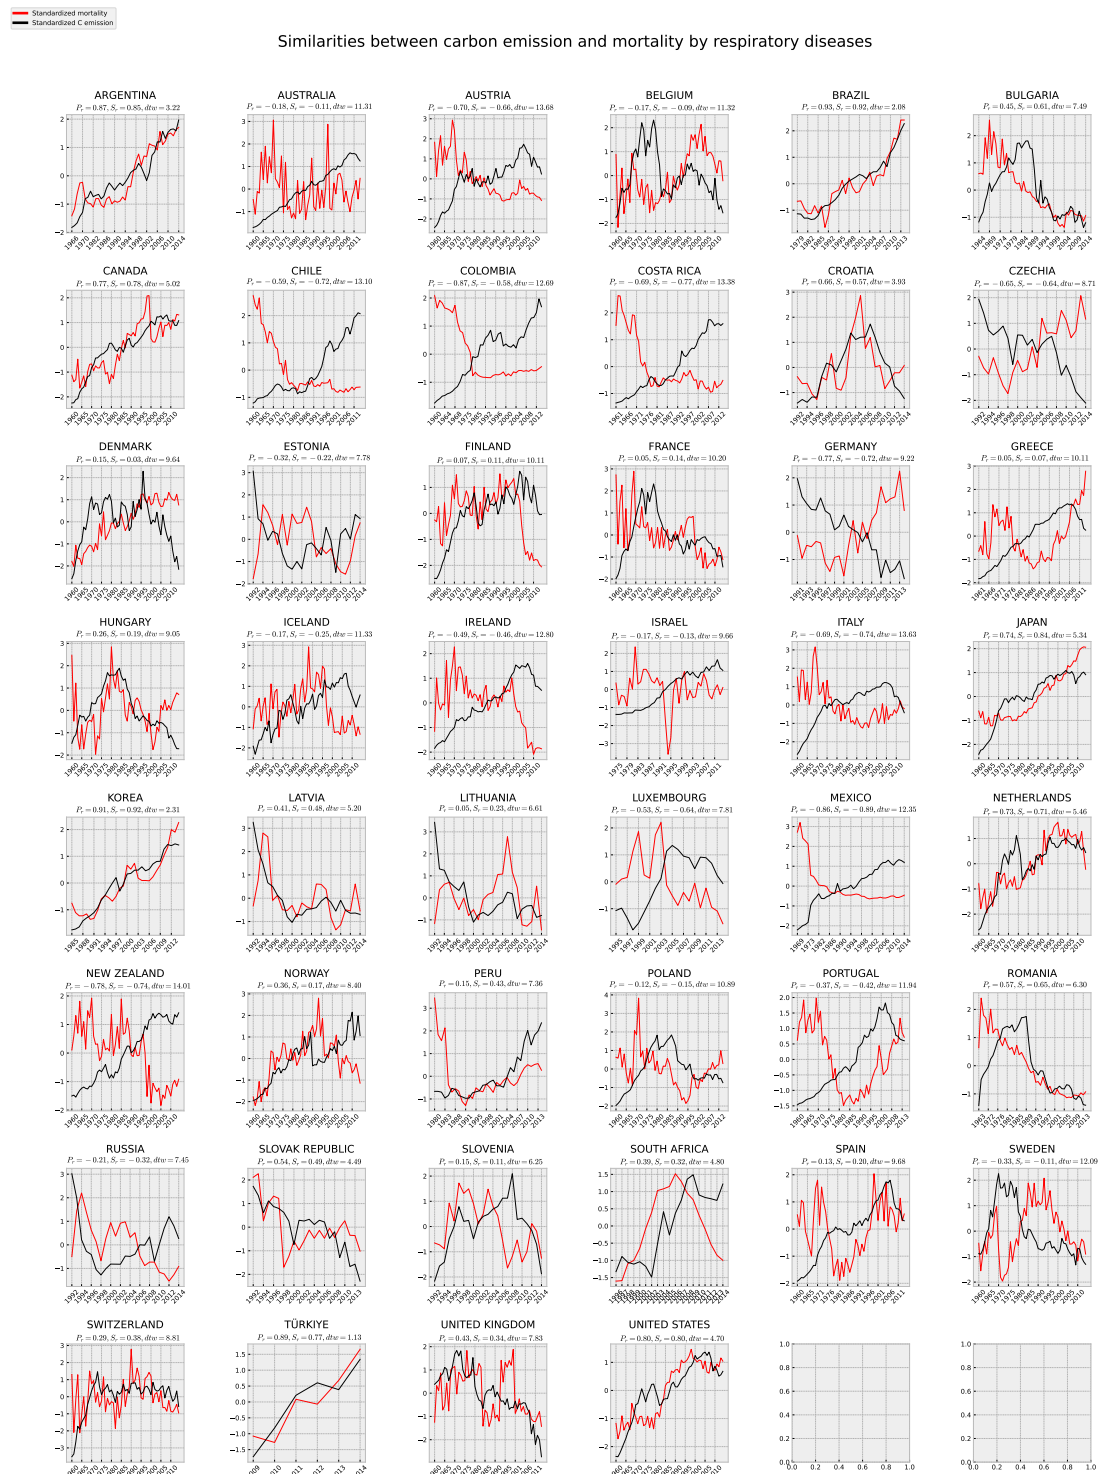


Figura 3. Similaridade entre a emissão de carbono e mortalidade por doenças respiratórias não ponderada

B. Similaridade entre a emissão de carbono e mortalidade de doenças respiratórias, ponderada pela expectativa de vida no nascimento, por país

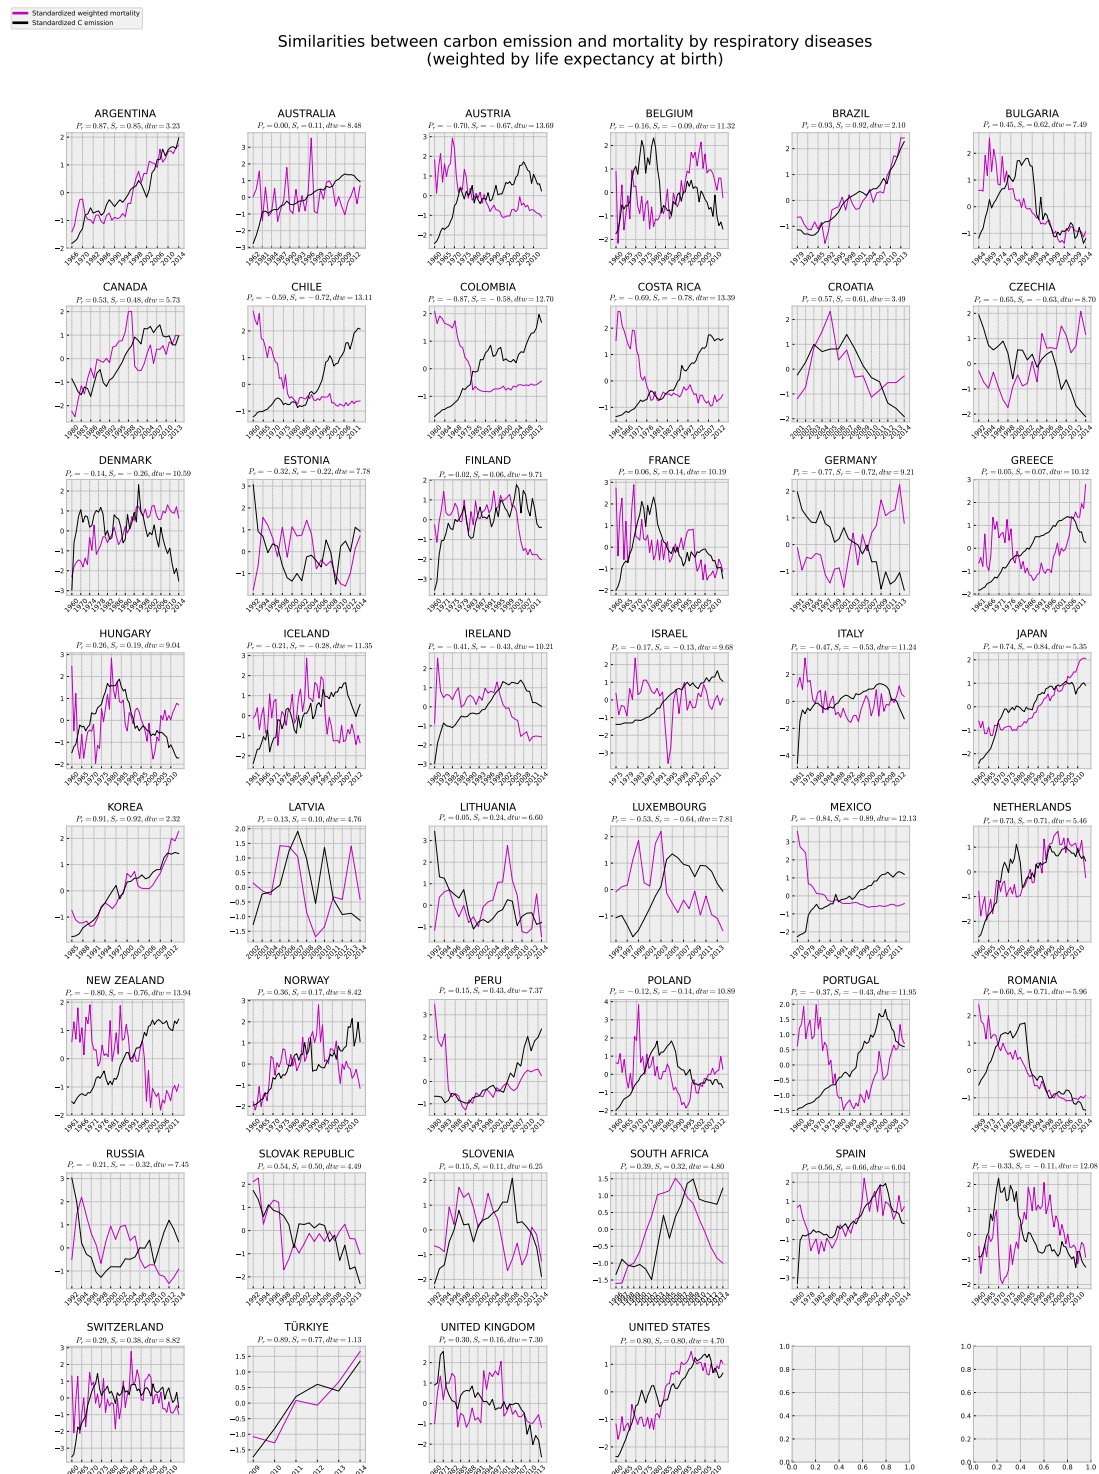


Figura 4. Similaridade entre a emissão de carbono e mortalidade por doenças respiratórias ponderada por expectativa de vida

C. Previsões de séries temporais para as emissões de carbono, por país

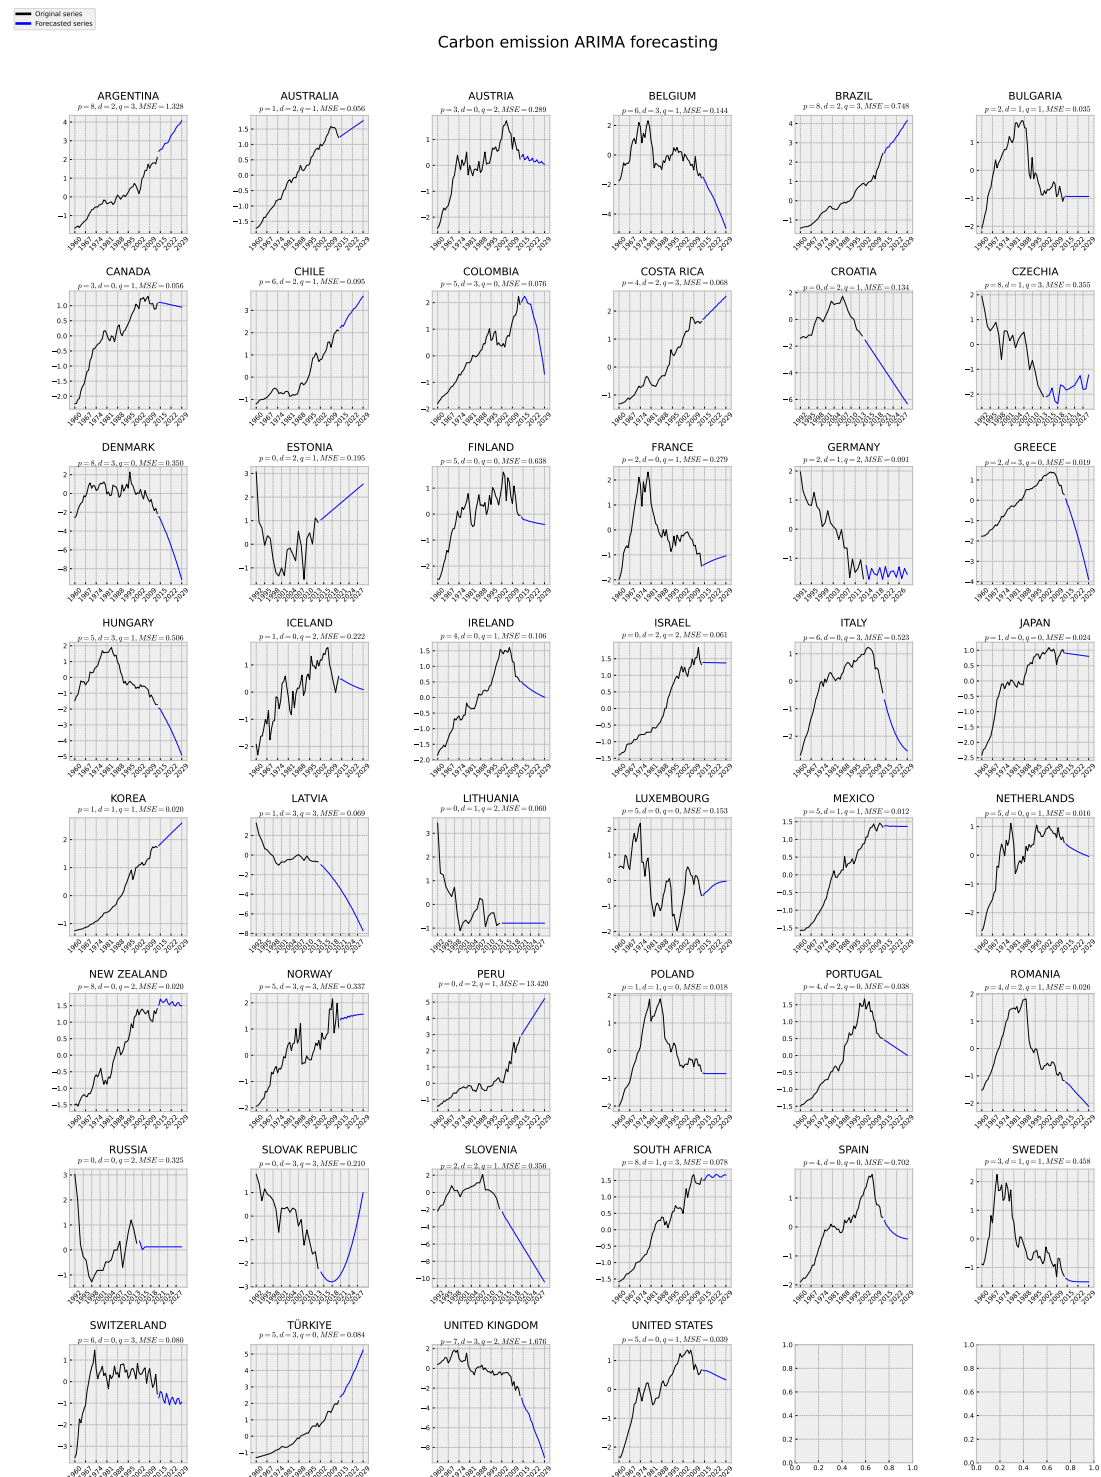


Figura 5. Previsões para emissões de carbono

D. Previsões para mortalidade de doenças respiratórias, por país

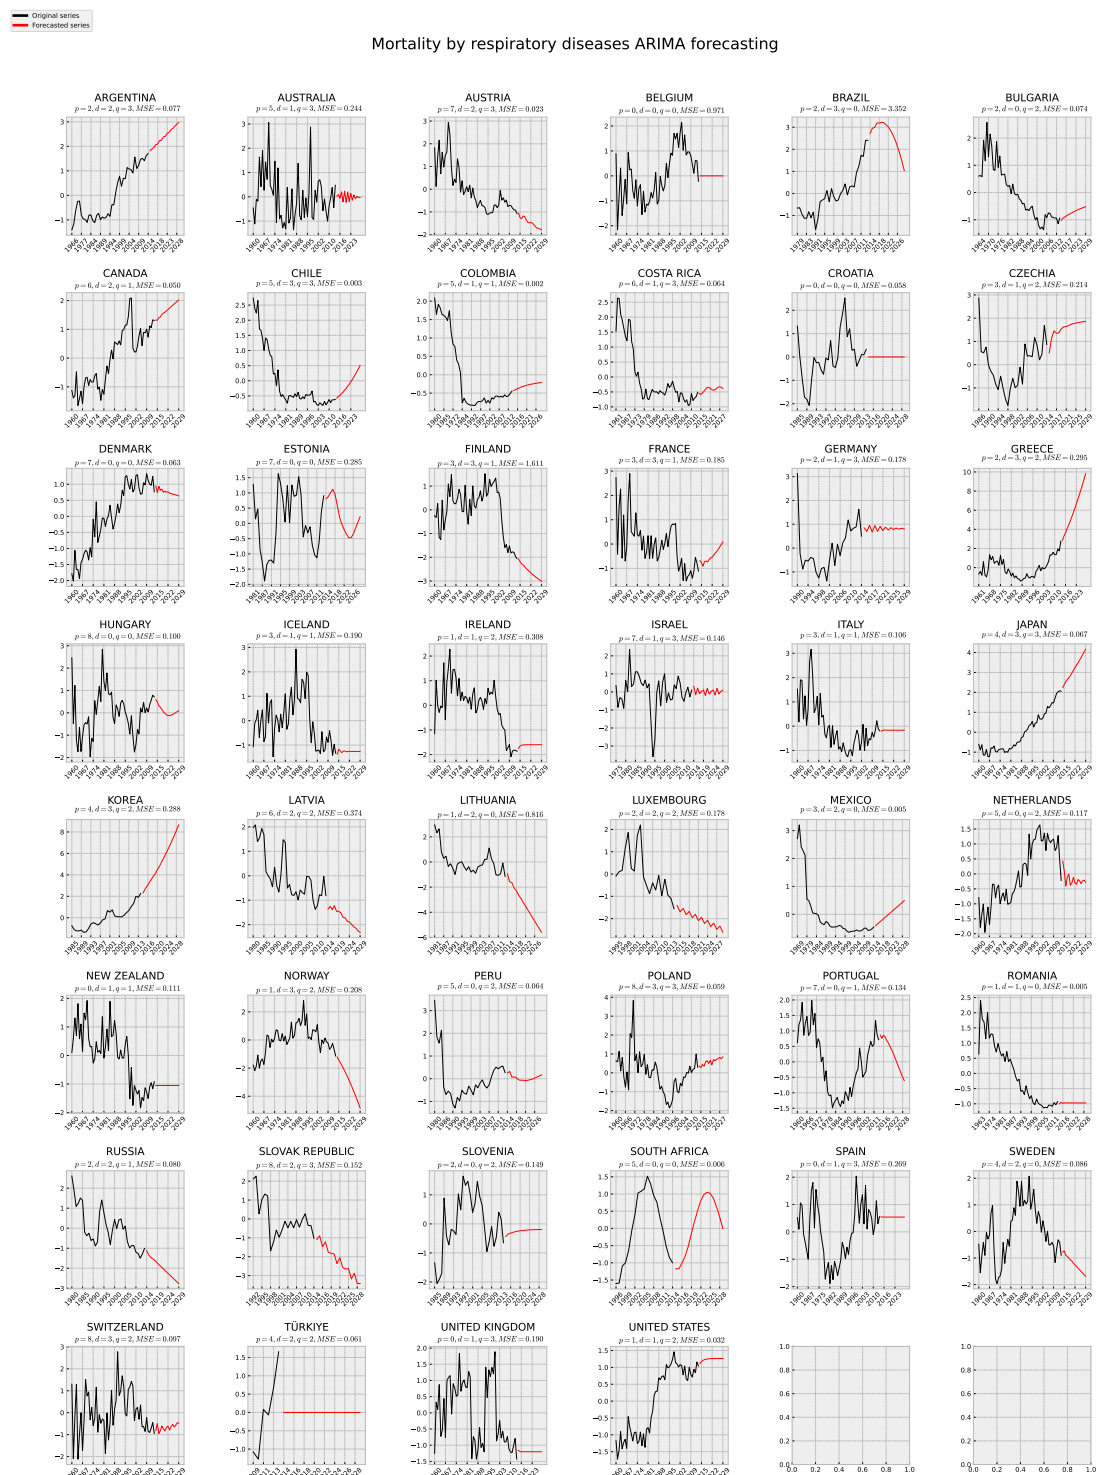


Figura 6. Previsões para mortalidade por doenças respiratórias

E. Previsões para mortalidade por doenças respiratórias, ponderada pela expectativa de vida no nascimento, por país

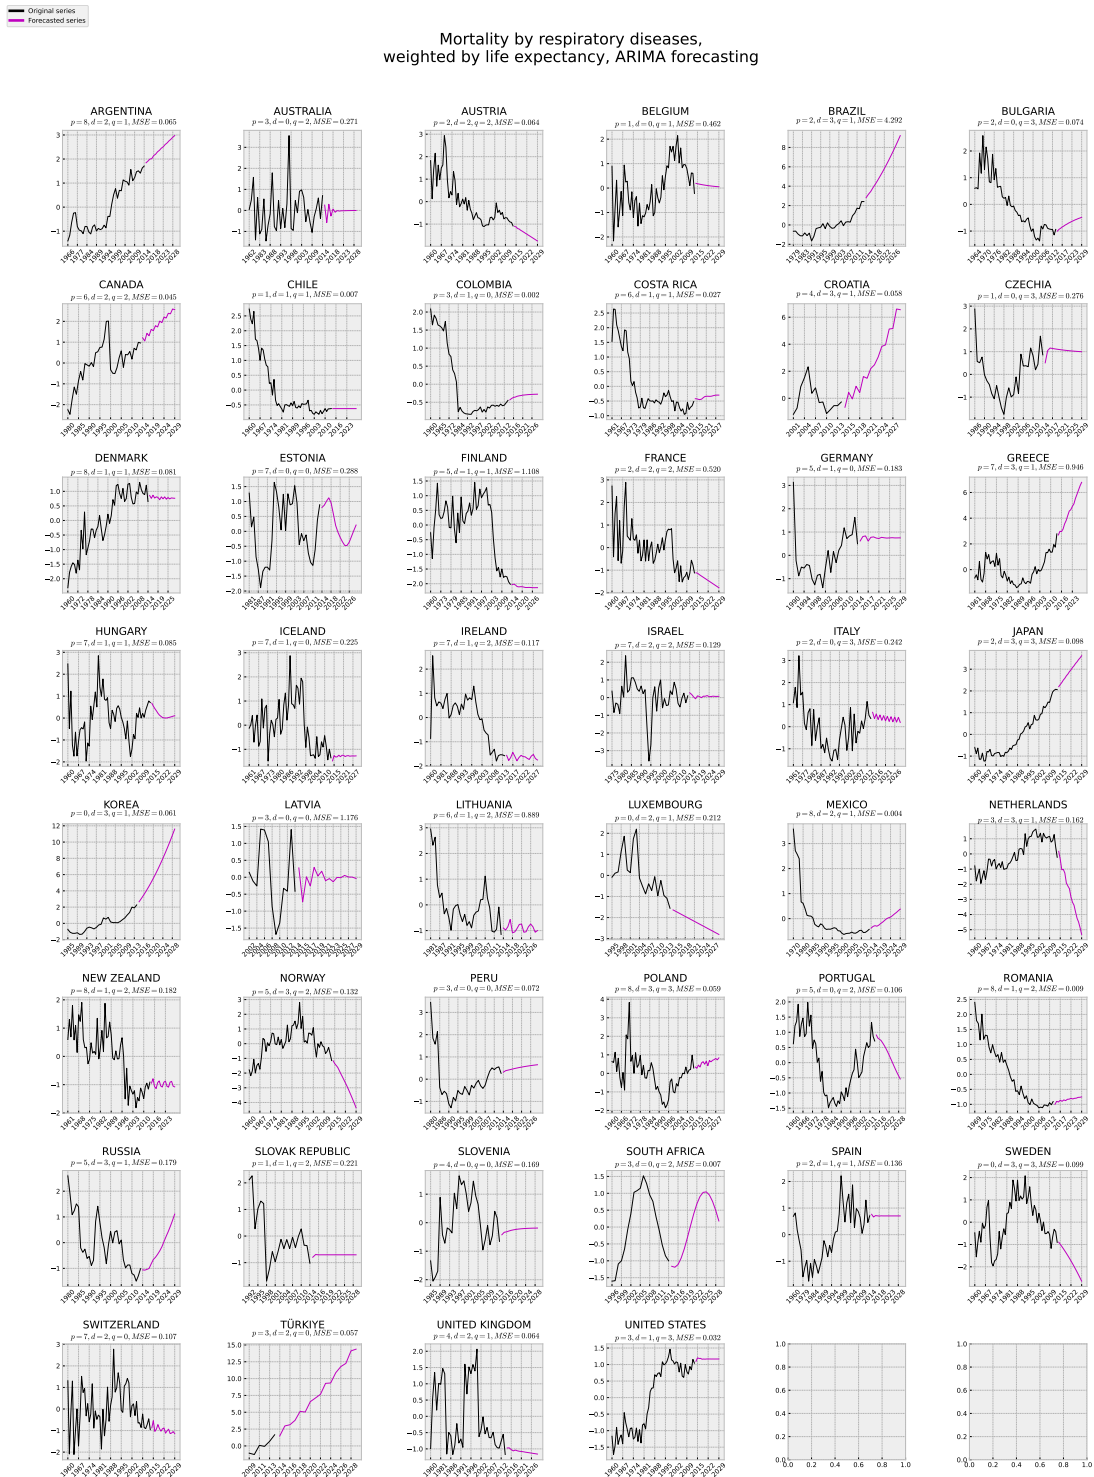


Figura 7. Previsões para mortalidade por doenças respiratórias ponderada pela expectativa de vida